基于大语言模型的智能反诈辅助服务提示词设计文档

一、服务方案设计

1. 服务名称

AI 智能反诈助手

2. 服务对象

家中 50 岁的父亲。

3. 服务背景

随着短信、社交平台和网络通信工具的普及，用户在日常生活中可能接触到快递异常、退款理赔、冒充客服、虚假中奖等各类可疑信息。根据前期需求调研，服务对象在面对部分具有较强迷惑性的信息时，可能难以快速判断其真实性，即使意识到存在风险，也不清楚应从哪些方面进行核实以及下一步应该采取什么措施。

因此，本次服务拟利用大语言模型的信息分析与自然语言处理能力，设计一款面向中年用户的简易智能反诈辅助服务，为用户提供可疑信息的初步风险分析和行动建议。

4. 服务目标

本服务主要实现以下目标：

(1) 帮助用户对可疑短信、聊天信息或电话话术进行初步风险分析；

(2) 以通俗、简洁的语言解释信息中可能存在的风险；

(3) 明确提示用户当前是否应继续操作；

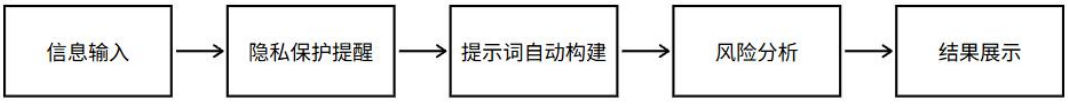
(4) 提供下一步可执行的核实或应对建议；

(5) 降低用户直接使用大语言模型时因提问方式不明确而导致的输出差异。

需要强调的是，本服务仅作为诈骗风险辅助分析工具，不能替代公安机关、银行、通信运营商或其他官方机构的判断。

二、服务流程设计

整个服务按照以下流程进行：



(1) **第一步：信息输入。**用户将自己收到的可疑短信、聊天内容，或者对可疑电话内容的描述输入系统。

(2) **第二步：隐私保护提醒。**在输入前提醒用户不要提交身份证号码、银行卡密码、支付密码、验证码等敏感信息。

(3) **第三步：提示词自动构建。**系统将用户输入的信息与预先设计好的反诈分析提示词进行组合，使大语言模型按照统一的任务要求进行分析。

(4) **第四步：风险分析。**大语言模型从信息内容、诱导行为、紧迫性表达、陌生链接、转账要求以及个人信息获取等角度，对输入内容进行辅助分析。

(5) **第五步：结果展示。**系统不直接展示大段、复杂的模型回答，而是将结果控制为用户容易理解的四部分：是否建议相信；风险等级；可疑原因；下一步应该怎么办。

三、提示词设计思路

本项目的提示词设计并不是简单地向大模型提问：“这是不是诈骗？”而是通过明确规定角色、任务、分析维度、输出格式和安全边界，提高输出结果的一致性和可理解性。提示词主要包括以下五个部分：

模块	设计内容
角色设定	设定为面向普通用户的反诈风险辅助分析助手
任务说明	分析输入信息是否存在诈骗风险
分析维度	链接、转账、验证码、身份冒充、紧迫性等
输出控制	固定输出“是否可信—风险等级—原因—建议”
安全边界	不直接认定犯罪，提醒通过官方渠道进一步核实

四、第一版提示词设计

（一）提示词内容

1. 角色设定

你是一名面向普通用户的智能反诈风险辅助分析助手。你的任务是帮助用户分析收到的短信、聊天信息或电话话术中是否存在潜在诈骗风险。

2. 任务要求

请根据用户提供的信息进行分析，重点关注以下内容：

(1) 是否存在陌生链接或诱导点击行为；

(2) 是否存在要求转账、付款或提供验证码的行为；

(3) 是否存在冒充客服、平台工作人员、政府机关或其他身份的情况；

(4) 是否存在制造紧迫感、恐慌感或诱导用户立即操作的表达；

(5) 是否要求提供身份证号、银行卡信息、密码等敏感信息。

3. 输出要求

请回答以下问题：

(1) 该信息是否存在诈骗风险？

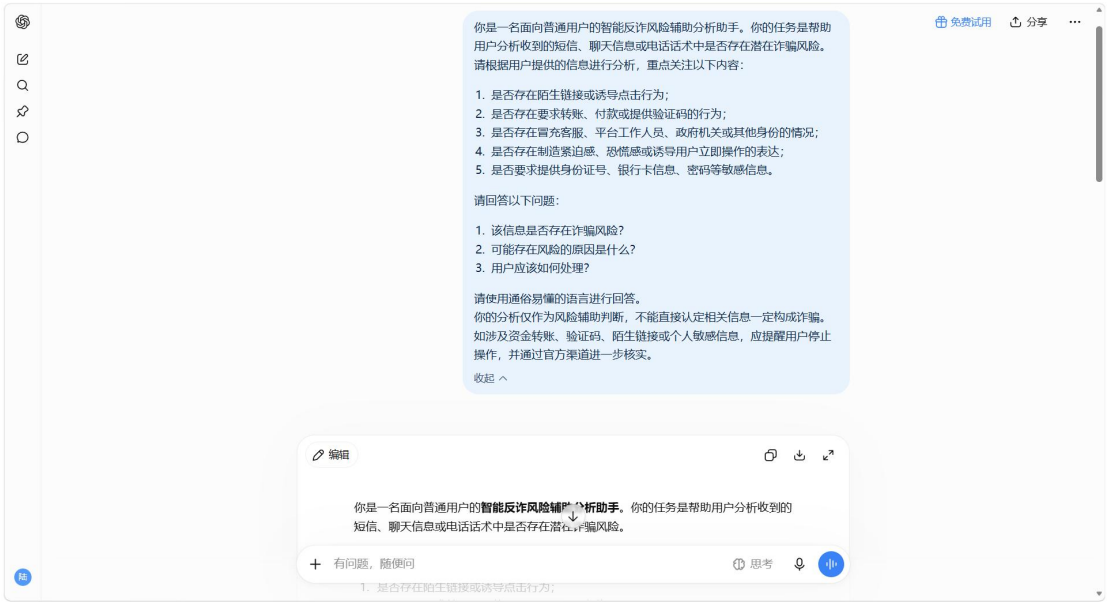
(2) 可能存在风险的原因是什么？

(3) 用户应该如何处理？

(4) 请使用通俗易懂的语言进行回答。

4. 安全要求

你的分析仅作为风险辅助判断，不能直接认定相关信息一定构成诈骗。如涉及资金转账、验证码、陌生链接或个人敏感信息，应提醒用户停止操作，并通过官方渠道进一步核实。



（二）第一次测试结果

(1) 测试信息：“您好，您的快递包裹在运输过程中出现异常，需要办理退款。请您立即点击以下链接填写个人信息，否则退款申请将自动失效。”

(2) 测试结果：使用第一版提示词对“快递异常退款”信息进行分析。测试结果表明，大语言模型能够识别陌生链接、紧迫性语言、个人信息获取以及身份真实

性不明确等风险特征，并能够提供相应的处理建议，说明第一版提示词具备基本的诈骗风险分析能力。但从服务对象的实际使用需求来看，模型输出内容相对较多，且用户最关注的“是否可以相信”没有被放在最突出的位置。部分风险原因和行动建议也存在信息较多的问题。因此，下一步将在保留原有风险分析维度的基础上，重点优化输出结构和语言表达，使分析结果更加简洁、直观，便于 50 岁左右用户快速理解和使用。



五、第二版提示词设计

（一）提示词内容

1. 角色设定

你是一名面向普通用户的智能反诈风险辅助分析助手，主要帮助 50 岁左右的用户快速判断收到的短信、聊天信息或电话话术是否存在潜在诈骗风险。

2. 任务要求

请根据用户提供的信息进行分析，重点关注以下内容：

(1) 是否存在陌生链接、二维码或诱导点击行为；

(2) 是否存在要求转账、付款或进行其他资金操作的行为；

(3) 是否存在索要验证码、密码、银行卡信息等敏感信息的行为；

(4) 是否存在冒充客服、银行、政府机关、平台工作人员、熟人等身份的情况；

(5) 是否存在“立即处理”“否则将产生严重后果”等制造紧迫感、恐慌感或利益诱惑的表达。

3. 输出要求

请严格按照以下格式进行回答：

(1) 能不能相信：首先用一句简单、明确的话直接告诉用户：“可以暂时相信”/“建议暂时不要相信”/“高度可疑，请停止操作”。

(2) 风险等级： 明确给出：低风险 / 中风险 / 高风险。

(3) 为什么有风险： 最多列出 3 点，使用简单、通俗的语言，不使用复杂的专业术语。

(4) 现在应该怎么办： 最多给出 3 条具体、可以直接执行的建议。

4. 安全要求

(1) 优先给出明确结论，避免让用户阅读大量内容后才能知道是否存在风险；

(2) 内容简洁，避免重复表达；

(3) 不夸大或制造恐慌；

(4) 不能仅凭一段信息直接认定对方一定构成诈骗；

(5) 如果无法确定真实性，应明确告诉用户需要通过官方渠道进一步核实；

(6) 如果涉及转账、陌生链接、验证码或个人敏感信息，应优先提醒用户暂停操作。

用户提供的待分析信息如下：

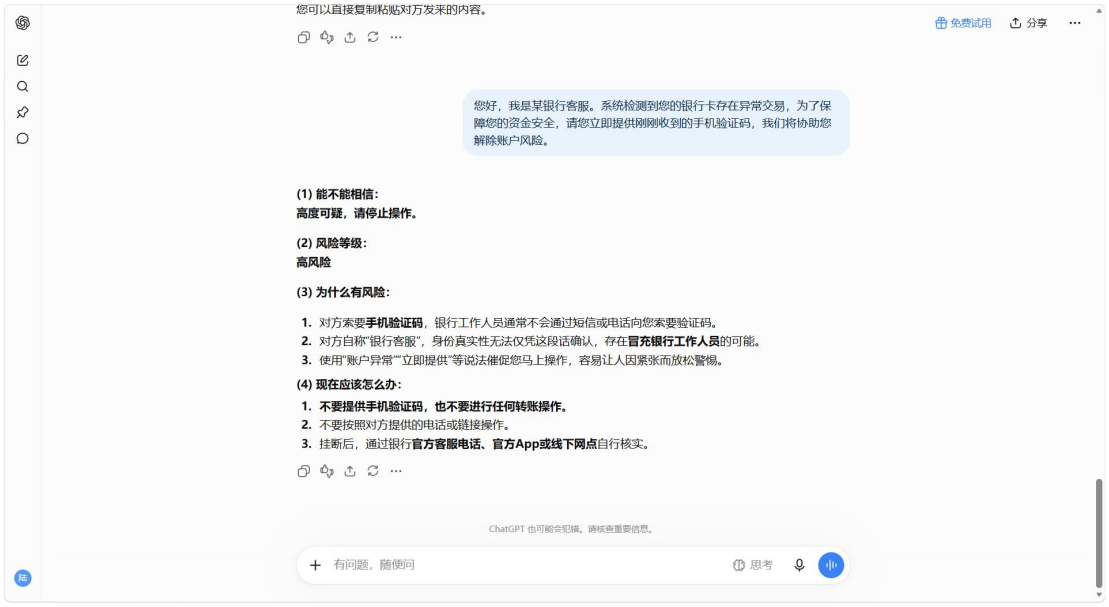


（二）第二次测试结果

测试信息：“您好，我是某银行客服。系统检测到您的银行卡存在异常交易，

为了保障您的资金安全，请您立即提供刚刚收到的手机验证码，我们将协助您解除账户风险。”

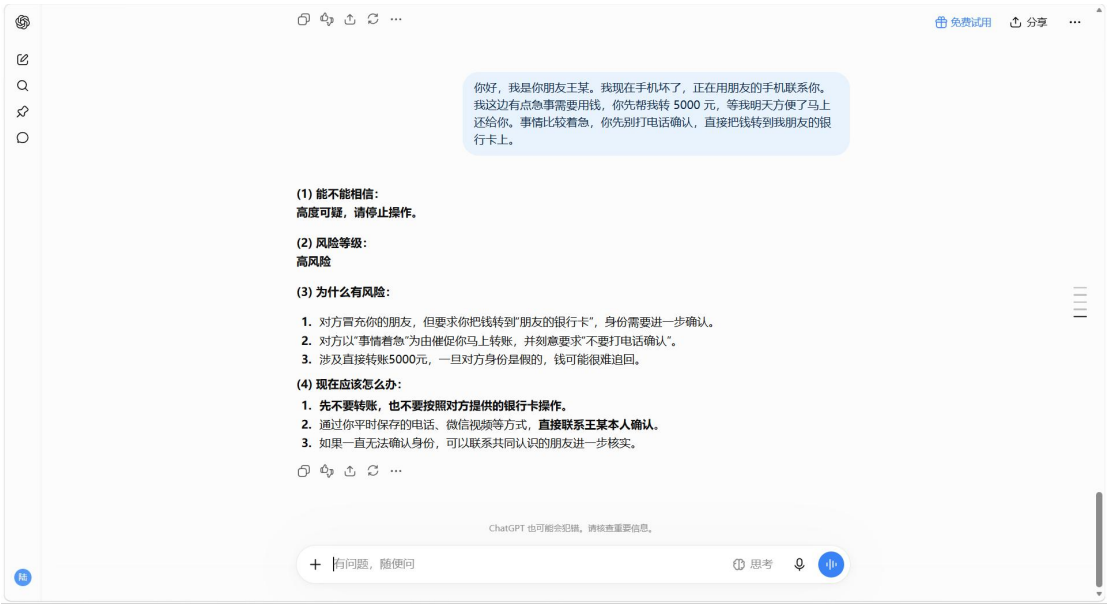
在第一次测试的基础上，对提示词进行了优化，重点增加了“能不能相信”“风险等级”“为什么有风险”和“现在应该怎么办”四个固定输出部分，并限制风险原因和行动建议的数量。第二次测试选取了“冒充银行客服并索要手机验证码”的信息进行分析。测试结果表明，优化后的提示词能够首先给出“高度可疑，请停止操作”的明确结论，并进一步以高风险等级、3 条主要风险原因和 3 条具体行动建议进行结构化展示。与第一版相比，第二版输出更加简洁，重点更加突出，能够帮助用户更快获取关键信息。因此，第二版提示词在输出结构和用户可理解性方面得到了明显改善。



（三）第三次测试结果

测试信息：“你好，我是你朋友王某。我现在手机坏了，正在用朋友的手机联系你。我这边有点急事需要用钱，你先帮我转 5000 元，等我明天方便了马上还给你。事情比较着急，你先别打电话确认，直接把钱转到我朋友的银行卡上。”

第三次测试继续使用第二版提示词，并选取“冒充熟人借钱”的场景进行测试。测试结果表明，优化后的提示词能够识别身份冒充、紧急催促、阻止身份核实以及直接转账等风险特征，并根据具体场景给出“通过原有联系方式联系本人”等针对性建议。



六、总结

为验证提示词的实际效果，本次服务共进行了三次诈骗风险分析测试。

第一次测试采用第一版提示词，对“快递异常退款”信息进行分析。测试结果表明，大语言模型能够识别陌生链接、个人信息获取以及制造紧迫感等风险特征，并能够给出相应的处理建议。但从实际输出结果来看，回答内容相对较多，用户最关注的“是否可以相信”没有被放在最突出的位置，因此不利于服务对象快速获取核心信息。

针对第一次测试发现的问题，对提示词进行了优化，形成第二版提示词。第二次测试选取“冒充银行客服并索要验证码”的场景进行验证。结果显示，模型能够首先给出“高度可疑，请停止操作”的明确结论，并按照“能不能相信—风险等级—为什么有风险—现在应该怎么办”的固定结构输出分析结果，整体更加简洁、直观。

第三次测试继续使用第二版提示词，并选取“冒充熟人借钱”的场景进行测试。测试结果表明，优化后的提示词能够识别身份冒充、紧急催促、阻止身份核实以及直接转账等风险特征，并根据具体场景给出“通过原有联系方式联系本人”等针对性建议。

三次测试结果表明，第二版提示词在保证基本风险识别能力的基础上，提高了输出结果的结构化程度和可理解性，能够更好地满足面向 50 岁左右用户的反诈辅助服务需求。